

OBS: Projeto Individual ou em Dupla

Dia da apresentação: 15/10/2026

Envio dos slides até: 14/10/2026

1 Problema

O objetivo deste trabalho é selecionar um dataset de classificação e Regressão (um para cada tarefa) disponível no *OpenML* (<https://www.openml.org/>) e realizar a avaliação de diferentes algoritmos de aprendizado de máquina supervisionado.

O banco de dados escolhido deve atender aos seguintes critérios:

- Conter mais de 10 atributos (variáveis preditoras);
- Ter mais de 1000 instâncias (amostras).

Cada um deverá informar antecipadamente, por meio de formulário (<https://forms.gle/gqLHCnVFUbsGRSuf6>), qual conjunto de dados será utilizado. Os classificadores a serem avaliados incluem, os seguintes algoritmos:

- (a) K-Nearest Neighbors (kNN): treine o classificador utilizando diferentes medidas de distância;

1. Distância Euclidiana

$$d_{\text{Euclidiana}}(X, Y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

2. Distância Manhattan

$$d_{\text{Manhattan}}(X, Y) = \sum_{i=1}^n |x_i - y_i|$$

- (b) Treine um classificador bayesiano - Caso Univariado. A função de densidade da distribuição normal univariada é dada por:

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right]$$

- (c) Treine um classificador bayesiano - Caso Multivariado. A função de densidade normal multi-variada em d dimensões é dada por:

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^t \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$

Matriz de covariância:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \sigma_{13} \\ \sigma_{21} & \sigma_2^2 & \sigma_{23} \\ \sigma_{31} & \sigma_{32} & \sigma_3^2 \end{bmatrix}$$

- $\mathbf{x}$ é um vetor coluna com d componentes
- $\boldsymbol{\mu}$ é o vetor de médias de d componentes
- Σ é a matriz de covariâncias $d \times d$
- $|\Sigma|$ é o determinante de Σ
- Σ^{-1} é a inversa de Σ
- $(\mathbf{x} - \boldsymbol{\mu})^t$ é a transposta de $(\mathbf{x} - \boldsymbol{\mu})$

OBS: No Python esta matriz pode ser encontrada ao utilizar a biblioteca numpy e aplicar (np.cov).

- (d) Calcule a média e o desvio padrão das métricas de avaliação, considerando todos os *folds* da validação cruzada. Em seguida, apresente os resultados em uma tabela comparativa, conforme o modelo abaixo.

Exemplo de Tabela com Médias, Desvio Padrão e Tempos

Classificador	Acurácia	Precisão	F1-Score	Tempo Treino (s)	Tempo Teste (s)
K-vizinhos (Dist. Euclidiana)	0.85 ± 0.03	0.84 ± 0.04	0.84 ± 0.04	0.12 ± 0.01	0.03 ± 0.00
K-vizinhos (Dist. Manhattan)	0.88 ± 0.02	0.87 ± 0.03	0.87 ± 0.03	0.11 ± 0.01	0.02 ± 0.00
... Bayesiano (Univariado)	0.87 ± 0.03	0.86 ± 0.03	0.86 ± 0.03	0.07 ± 0.01	0.01 ± 0.00

Tabela 1: Análise comparativa do desempenho dos classificadores, com médias, desvios padrão ($\pm$) e tempos de treino e teste.

- (e) Os regressores a serem avaliados incluem, os seguintes algoritmos:

- K-Nearest Neighbors (kNN): Distancia Euclidiana e Manhattan;
- Regressão linear Multipla;

A comparação de desempenho será feita por meio das métricas:

- *Accuracy*;
- *F1-score*;
- *Precision*;
- *Recall*;
- *R2_score*;
- *R2_score ajustado*;

2 Estrutura Mínima do Trabalho

O projeto deve conter, no mínimo, as seguintes seções:

1. **Introdução:** Escrever um texto curto explicando: Qual é o objetivo do trabalho; O que você vai comparar (algoritmos); Por que isso é importante.
2. **Algoritmos de Aprendizagem de Máquina:** Explicar como cada algoritmo funciona (conceito + ideia matemática básica).
3. **Experimentos**
 - 3.1. **Banco de Dados:** Descrever os datasets escolhidos; Mostrar: Quantidade de amostras; Número de atributos; O que o dataset representa.
 - 3.2. **Métricas de Avaliação:** Explicar as métricas usadas.
 - 3.3. **Resultados:** Rodar validação cruzada (ex: 5-fold); Para cada algoritmo calcular: Média; Desvio padrão; Tempo de treino; Tempo de teste; Montar a tabela comparativa.
4. **Conclusões:** Qual algoritmo foi melhor? Qual foi mais rápido? Vale a pena o mais preciso ou o mais rápido? Limitações observadas.
5. **Referências:** Listar fontes usadas.

Análise Comparativa dos Classificadores e Regressores

Com base na Tabela 1, elabore uma análise crítica considerando:

- Comparação das métricas entre os classificadores (Acurácia e F1-Score);
- Comparação das métricas entre os regressores (R^2 score e MAE);
- Diferenças nos tempos de treino e teste;
- Relação entre desempenho e eficiência computacional;
- Pontos fortes e limitações observadas em cada algoritmo.

Apresente, ao final, qual classificador e regressor apresentou melhor equilíbrio entre desempenho e tempo de execução para o problema analisado.

Observações Importantes

- A entrega das implementações é **obrigatória**. Trabalhos sem código entregue receberão **nota zero**.
- A pontualidade será um critério avaliativo.
- Não é permitido o uso de bibliotecas que implementem diretamente os algoritmos (por exemplo, `scikit-learn`) nem o uso de `pandas`. Todo o código deve ser implementado manualmente.
- Os slides da apresentação deverão ser enviados no AVA dentro do prazo estabelecido. Devem conter:
 - Introdução e justificativa do dataset escolhido;
 - Resultados e comparações;
 - Conclusões gerais.
- Não é necessário entregar um relatório escrito além dos slides.
- Caso algum aluno não consiga apresentar, deverá agendar uma avaliação individual. Caso contrário, será atribuída **nota zero**.
- Trabalhos enviados fora do prazo estabelecido **nota zero**.